

SEDUC - PACD - Semana 18 - Aula 4

Roteiro Passo a Passo com Resolução Comentada

Atividade: Operação Limpeza - Integridade e Qualidade de Dados

1. Abrir o ambiente

O que fazer:

Abra o Jupyter Notebook ou VS Code e deixe os arquivos CSV na mesma pasta.

Resolução/Resultado: Resultado esperado: os arquivos são localizados sem erro pelo Python.

2. Importar o Pandas

O que fazer:

```
import pandas as pd
```

Resolução/Resultado: A biblioteca Pandas será carregada para manipular tabelas.

3. Carregar os arquivos

O que fazer:

```
df_produtos = pd.read_csv("DADOSANO1C2B3S18A4_PRODUTOS.csv", sep=";")  
df_vendas = pd.read_csv("DADOSANO1C2B3S18A4_VENDAS.csv", sep=";")
```

Resolução/Resultado: Os dois DataFrames são criados com os dados dos arquivos CSV.

4. Identificar valores ausentes

O que fazer:

```
df_produtos.isnull().sum()
```

Resolução/Resultado: Será identificado pelo menos um valor ausente na coluna VLR_custo.

5. Calcular a média dos custos

O que fazer:

```
media_custo = df_produtos["VLR_custo"].mean()
```

Resolução/Resultado: A média encontrada é aproximadamente 6,84.

6. Preencher valores ausentes

O que fazer:

```
df_produtos["VLR_custo"] = df_produtos["VLR_custo"].fillna(media_custo)
```

Resolução/Resultado: O produto que estava sem custo passa a receber o valor médio 6,84.

7. Remover quantidades vazias

O que fazer:

```
df_vendas = df_vendas.dropna(subset=["Quantidade"])
```

Resolução/Resultado: As vendas sem quantidade registrada são removidas da análise.

8. Verificar duplicatas

O que fazer:

```
df_vendas.duplicated().sum()
```

Resolução/Resultado: Será detectado um registro duplicado na tabela de vendas.

9. Remover duplicatas

O que fazer:

```
df_vendas = df_vendas.drop_duplicates()
```

Resolução/Resultado: A tabela permanece apenas com registros únicos.

10. Exportar arquivos

O que fazer:

```
df_produtos.to_csv("produtos_limpos.csv", sep=";", index=False, encoding="utf-8-sig")  
df_vendas.to_csv("vendas_limpas.csv", sep=";", index=False, encoding="utf-8-sig")
```

Resolução/Resultado: Dois novos arquivos limpos são salvos.

11. Conferência Final

O que fazer:

Verificar tabelas finais.

Resolução/Resultado: Produtos: todos possuem custo preenchido. Vendas: sem quantidades vazias e sem duplicatas.

Gabarito Resumido

- Média da coluna VLR_custo: aproximadamente 6,84.
- Valores nulos em VLR_custo preenchidos pela média.
- Linhas com Quantidade vazia removidas.
- Registros duplicados removidos.
- Arquivos finais: produtos_limpos.csv e vendas_limpas.csv.